Forelesning 3: Deskriptiv statistikk i kjemi

Del 1: Hvorfor varierer målinger?

Diskuter: Fire gjentatte målinger av samme te gir omtrent symmetriske data. Vi regner ut gjennomsnitt og standardavvik, gjerne også RSD for å vurdere presisjonen og et 95 % konfidensintervall for å vise hvor sikkert vi kjenner koffeinkonsentrasjonen.

Del 2: Hvor ligger målingene?

[2]:
```
iron_mg_L = np.array([5.12, 5.08, 5.15, 5.10, 5.13])

mean = np.mean(iron_mg_L)
median = np.median(iron_mg_L)

print(f"Mean: {mean:.3f} mg/L")
print(f"Median: {median:.3f} mg/L")
```

```
Mean: 5.116 mg/L
Median: 5.120 mg/L
```

[3]:
```
series_1 = np.array([10.02, 10.05, 9.98, 10.01, 10.04])
series_2 = np.array([10.02, 10.05, 9.98, 10.01, 10.42])

print(f"Mean: {np.mean(series_1):.3f}   Median: {np.median(series_1):.3f}")
print(f"Mean: {np.mean(series_2):.3f}   Median: {np.median(series_2):.3f}")
```

```
Mean: 10.020   Median: 10.020
Mean: 10.096   Median: 10.020
```

Gjennomsnittet øker fra 10,020 til 10,096, mens medianen er 10,02 i begge seriene.

Del 3: Persentiler og boksplott

[4]:
```
nitrate_mg_L = np.array([0.42, 0.47, 0.50, 0.55, 0.58, 0.61,
                         0.65, 0.72, 0.85, 1.10, 1.35, 2.80])

q1 = np.percentile(nitrate_mg_L, 25)
median = np.percentile(nitrate_mg_L, 50)
q3 = np.percentile(nitrate_mg_L, 75)

print(f"Q1: {q1:.2f} mg/L   Median: {median:.2f} mg/L   Q3: {q3:.2f} mg/L")
print(f"Mean: {np.mean(nitrate_mg_L):.2f} mg/L")
```

```
Q1: 0.54 mg/L   Median: 0.63 mg/L   Q3: 0.91 mg/L
Mean: 0.88 mg/L
```

Diskuter: Bekken har høyere nitratkonsentrasjon enn omtrent 75 % av bekkene. Gjennomsnittet er høyere enn medianen fordi noen få bekker med høye verdier, særlig 2,80 mg/L, trekker gjennomsnittet opp. Fordelingen er skjev.

Boksplott

[5]:
```
plt.boxplot(nitrate_mg_L, orientation="horizontal")
plt.xlabel("Nitrate concentration (mg/L)")
plt.title("Nitrate in stream-water samples")
plt.show()
```

Del 4: Hvor mye varierer dataene?

[6]:
```
data_range = np.max(nitrate_mg_L) - np.min(nitrate_mg_L)
iqr = q3 - q1

print(f"Range: {data_range:.2f} mg/L")
print(f"IQR: {iqr:.2f} mg/L")
```

```
Range: 2.38 mg/L
IQR: 0.37 mg/L
```

Standardavvik

[7]:
```
sd = np.std(iron_mg_L, ddof=1)
print(f"SD: {sd:.3f} mg/L")
```

```
SD: 0.027 mg/L
```

Relativt standardavvik (RSD)

[8]:
```
def rsd(measurements):
    return np.std(measurements, ddof=1) / np.mean(measurements) * 100

print(f"RSD: {rsd(iron_mg_L):.2f} %")
```

```
RSD: 0.53 %
```

Diskuter: Metode A har minst standardavvik, men RSD er 5 %. Metode B har RSD 0,2 % og dermed best relativ presisjon. RSD blir misvisende når gjennomsnittet er nær null, for eksempel nær deteksjonsgrensen.

Hva bruker vi når?

1. Gjennomsnitt og standardavvik, eventuelt med konfidensintervall
2. Median og IQR
3. Median og IQR, fordi fordelingen trolig er skjev

Del 5: Hvor sikkert kjenner vi gjennomsnittet?

[9]:
```
n = len(iron_mg_L)
mean = np.mean(iron_mg_L)
sd = np.std(iron_mg_L, ddof=1)
se = sd / np.sqrt(n)

t_factor = t.ppf(0.975, n - 1)   # 97,5 % fordi intervallet er tosidig
margin = t_factor * se

print(f"Mean: {mean:.3f} mg/L")
print(f"95 % CI: [{mean - margin:.3f}, {mean + margin:.3f}] mg/L")
```

```
Mean: 5.116 mg/L
```

```
95 % CI: [5.082, 5.150] mg/L
```

[ ]:
```python
def confidence_interval(measurements, level=0.95):
    n = len(measurements)
    mean = np.mean(measurements)
    se = np.std(measurements, ddof=1) / np.sqrt(n)
    t_factor = t.ppf(1 - (1 - level) / 2, n - 1)
    return mean - t_factor * se, mean + t_factor * se

lower, upper = confidence_interval(iron_mg_L, level)
print(f"Konfidensintervall: [{lower:.3f}, {upper:.3f}] mg/L")
```

```
90%: [5.090, 5.142] mg/L
95%: [5.082, 5.150] mg/L
99%: [5.060, 5.172] mg/L
```

Diskuter: Intervallet blir bredere når konfidensnivået øker. Flere målinger eller mindre spredning gjør det smalere. Ti avlesninger av samme kyvette fanger bare opp støyen i instrumentet, ikke variasjonen fra pipettering og fortynning.

Rapportering og avrunding

- 0,60433 ± 0,003786 rapporteres som 0,6043 ± 0,0038
- 12,4150 ± 0,0271 rapporteres som 12,415 ± 0,027

Del 6: Feilstolper

[11]:
```python
concentration_mg_L = np.array([0.2, 0.3, 0.4, 0.5, 0.6])
absorbance = np.array([
    [0.21, 0.22, 0.19],
    [0.26, 0.29, 0.24],
    [0.33, 0.33, 0.34],
    [0.41, 0.42, 0.45],
    [0.56, 0.61, 0.58],
])

mean_abs = np.mean(absorbance, axis=1)
sd_abs = np.std(absorbance, axis=1, ddof=1)
n = 3
se_abs = sd_abs / np.sqrt(n)
ci_abs = t.ppf(0.975, n - 1) * se_abs

plt.errorbar(concentration_mg_L, mean_abs, yerr=ci_abs, fmt="o", capsize=4)
plt.xlabel("Mg concentration (mg/L)")
plt.ylabel("Absorbance")
plt.title("Error bars: 95 % CI (n = 3)")
plt.show()
```

Diskuter: Med $n = 3$ er t-faktoren 4,30, mens $\sqrt{3} \approx 1{,}73$. Feilmarginen til konfidensintervallet blir derfor $4{,}30/1{,}73 \approx 2{,}5$ ganger standardavviket. SD, SE og KI kan gi feilstolper som ser like ut, men de betyr helt forskjellige ting, så figurteksten må si hvilken som er brukt.

Del 7: Statistikk med Pandas

[12]:
```
calibration =
  pd.read_csv("../datahandtering_visualisering/data/uvvis_calibration.csv")
standards = calibration[calibration["sample_type"] == "standard"]

summary = standards.groupby("concentration_uM")["absorbance"].agg(["count", "mean",
  "std"])
summary["rsd_percent"] = summary["std"] / summary["mean"] * 100
summary
```

[12]:

concentration_uM	count	mean	std	rsd_percent
2.0	3	0.170667	0.001528	0.895034
4.0	3	0.329333	0.001528	0.463823
6.0	3	0.489000	0.002000	0.408998
8.0	3	0.650000	0.002000	0.307692
10.0	3	0.809333	0.002517	0.310949

[13]:
```
unknown = calibration[calibration["sample_type"] == "unknown"]["absorbance"]

print(unknown.describe())
print(f"RSD: {rsd(unknown):.2f} %")
lower, upper = confidence_interval(unknown)
print(f"95 % CI: [{lower:.4f}, {upper:.4f}]")
```

```
count    3.000000
mean     0.604333
std      0.001528
min      0.603000
25%      0.603500
50%      0.604000
75%      0.605000
max      0.606000
Name: absorbance, dtype: float64
RSD: 0.25 %
95 % CI: [0.6005, 0.6081]
```

Resultat: 0,6043 ± 0,0038 (95 % KI).

Diskuter: Standardavviket beskriver spredningen i de tre målingene. Konfidensintervallet forteller hvor sikkert vi kjenner gjennomsnittet. Ingen av dem sier noe om systematiske feil, for eksempel en feil i standardløsningene.

Oppgaver

Oppgave 1

[14]:
```
copper_mg_kg = np.array([12, 14, 15, 16, 18, 21, 29, 47])

print(f"Q1: {np.percentile(copper_mg_kg, 25):.2f} mg/kg")
print(f"Median: {np.percentile(copper_mg_kg, 50):.2f} mg/kg")
print(f"Q3: {np.percentile(copper_mg_kg, 75):.2f} mg/kg")

plt.boxplot(copper_mg_kg, orientation="horizontal")
plt.xlabel("Copper concentration (mg/kg)")
plt.show()
```

```
Q1: 14.75 mg/kg
Median: 17.00 mg/kg
Q3: 23.00 mg/kg
```

Omtrent 25 % av prøvene har under 14,75 mg/kg, halvparten under 17 mg/kg og 75 % under 23 mg/kg. Prøven med 47 mg/kg ligger utenfor værhårene.

Oppgave 2

[ ]:
```
data = np.array([4.91, 5.03, 4.98, 5.01, 5.07])
data_extra = np.append(data, 5.80)

for x in [data, data_extra]:
    data_range = np.max(x) - np.min(x)
    iqr = np.percentile(x, 75) - np.percentile(x, 25)
    print(f"Mean: {np.mean(x):.3f}   Median: {np.median(x):.3f}   Range:
  {data_range:.2f}   IQR: {iqr:.2f}")
```

Variasjonsbredden påvirkes mest, fordi den bare bruker største og minste verdi. Gjennomsnittet øker også merkbart. Medianen og IQR endres lite, fordi de bare bruker de midterste verdiene.

Oppgave 3

[16]:
```
measurements_mg_L = np.array([12.42, 12.38, 12.45, 12.41, 12.39, 12.44])

mean = np.mean(measurements_mg_L)
sd = np.std(measurements_mg_L, ddof=1)
se = sd / np.sqrt(len(measurements_mg_L))
lower, upper = confidence_interval(measurements_mg_L)

print(f"Mean: {mean:.4f} mg/L")
print(f"SD: {sd:.4f} mg/L")
print(f"SE: {se:.4f} mg/L")
print(f"95 % CI: [{lower:.3f}, {upper:.3f}] mg/L   margin: {upper - mean:.4f} mg/L")
```

```
Mean: 12.4150 mg/L
SD: 0.0274 mg/L
SE: 0.0112 mg/L
95 % CI: [12.386, 12.444] mg/L   margin: 0.0287 mg/L
```

Resultat: 12,415 ± 0,029 mg/L (95 % KI). Intervallet blir smalere med flere målinger eller med en mer presis metode, for eksempel mer nøyaktig pipettering.

Oppgave 4

Den første studenten fanger bare opp støyen i instrumentet. Den andre fanger også opp variasjon fra veiing, pipettering, fortynning og kyvetteplassering. Det andre forsøket sier mest om presisjonen til analysemetoden.

Oppgave 5

[17]:
```
for data in [measurements_mg_L[:3], measurements_mg_L]:
    lower, upper = confidence_interval(data)
    print(f"n = {len(data)}: [{lower:.3f}, {upper:.3f}] mg/L   width: {upper -
  lower:.3f} mg/L")
```

```
n = 3: [12.329, 12.504] mg/L   width: 0.174 mg/L
n = 6: [12.386, 12.444] mg/L   width: 0.057 mg/L
```

Intervallet for tre målinger er mye bredere. Standardfeilen $s/\sqrt{n}$ blir større med færre målinger, og t-faktoren øker fra 2,57 ($n = 6$) til 4,30 ($n = 3$).